

Informatik II: Algorithmen und Datenstrukturen SS 2017

Vorlesung 11a, Dienstag, 11. Juli 2017
(Editierdistanz, Teil 1)

Prof. Dr. Hannah Bast
Lehrstuhl für Algorithmen und Datenstrukturen
Institut für Informatik
Universität Freiburg

Blick über die Vorlesung heute

■ Organisatorisches

- Erfahrungen ÜB10

Routenplanung in BW / SL

■ Inhalt

- Editierdistanz

Motivation + Notation

- Rekursive Berechnung

monotone Folgen

- Rekursive Implementierung

Code + Laufzeit

- ÜB11: diesmal wieder ein reines Theorieblatt 🤔 🤔 🤔

■ Zusammenfassung

- Schöne Aufgabe mit Praxisbezug, hat vielen Spaß gemacht
- Einige Kämpfe mit dem Design / Code / Debuggen

Extra weniger Vorgaben diesmal, ist ja schon das ÜB10

Es hat sich aber gezeigt, dass viele noch Probleme mit der Umsetzung eines abstrakten Algorithmus in Code haben

- Einigen ist offenbar nicht klar, wie Sie richtig testen sollen

Jede Funktion einzeln, siehe 10 Gebote auf dem ÜB10

Grundsätzlich auf kleinen Beispielen, das geht **immer**

- Einige haben etwas Zeit gebraucht, um zu verstehen, was der "längste kürzeste Weg" ist

■ Ergebnis

- Erklärung längster kürzester Pfad ab einem Startknoten **s**

Der Zielknoten v , für den $\text{dist}(s, v)$ maximal ist

Wobei $\text{dist}(s, v)$ der kürzeste Weg von s nach v ist

- Längster kürzester Weg ab der Freiburger TF in BaWü:

<http://share.mapbbcode.org/cusya> "Auf zur Kunigundenkapelle"

- Längster kürzester Weg ab der Informatik im Saarland:

<http://share.mapbbcode.org/psdbh> eine Kreuzung, laangweilig

■ Motivation

- Es gibt viele Anwendungen, wo man ein Maß für die Ähnlichkeit zwischen zwei Zeichenketten braucht

Drei Beispiele dazu auf der nächsten Folie

- Die **Editierdistanz** ist ein solches Ähnlichkeitsmaß

Das in der Praxis am häufigsten verwendete Maß

Definition auf Folie 7

Benannt nach dem **Edi-Tier**



■ Anwendungsbeispiele

- Beispiel 1: Dubletten in Adressdatenbanken

Hein Blöd, 27568 Bremerhaven

Hein Bloed, 27568 Bremerhafen

Hein Doof, 27478 Cuxhaven

- Beispiel 2: Produktsuche

Memori Stik

- Beispiel 3: Websuche

eyjaföllajaküll

semesta verien 2017

■ Definition Editierdistanz ... alternativ: Levenshtein-Distanz

- Gegeben zwei Zeichenketten x und y
- $ED(x, y)$ = die minimale Anzahl der folgenden Operationen, die man braucht, um x in y zu transformieren:

Einfügen (**insert**) eines Buchstabens

Ersetzen (**replace**) eines Buchstabens durch einen anderen

Löschen (**delete**) eines Buchstabens

- Die Position einer Operation ist die Stelle im String, an der etwas geändert wird ... siehe Beispiel nächste Folie

Positionen fangen hier und in der Folge mit **1** an, nicht 0
(weil das intuitiver ist bei der mathematischen Analyse)

Editierdistanz 4/9

DOOF
SAUDOO F

UNI
FREIBURG

■ Beispiel

– $x = \text{DOOF}$, $y = \text{BLOED}$... $\text{ED}(x, y) = ?$

¹ ² ³ ⁴
D O O F
B O O F } REPLACE(1, B)
B L O F } REPLACE(2, L)
B L O E F } INSERT(4, E)
B L O E D } REPLACE(5, D)
B L O E D

Das ist eine
manatane
Folge (s. Folie 14)
 $1 < 2 < 4 < 5$

Damit haben wir erstmal nur
gezeigt: $\text{ED}(x, y) \leq 4$

■ Notation

- Mit ε bezeichnen wir das leere Wort
- Mit $|x|$ bezeichnen wir die Länge von x (= Anzahl Zeichen)
- Mit $x[i..j]$ bezeichnen wir die Teilfolge der Zeichen i bis j der Zeichenkette x , wobei $1 \leq i \leq j \leq |x|$

Wie gesagt: Positionen / Indizes fangen mit **1** an, nicht 0

$x = \overset{1}{B} \overset{2}{L} \overset{3}{O} \overset{4}{E} \overset{5}{D}$, $|x| = 5$, $x[2..4] = LOE$

■ Ein paar einfache Eigenschaften

- $ED(x, y) = ED(y, x)$
- $ED(x, \varepsilon) = |x|$
- $ED(x, y) \geq \text{abs}(|x| - |y|)$ $\text{abs}(x) = x > 0 ? x : -x$
- $ED(x, y) \leq \max(|x|, |y|)$
- $ED(x, y) \leq ED(x[1..n-1], y[1..m-1]) + 1$ $n = |x|, m = |y|$
- Die Beweise sind alle einfache Zwei- oder Dreizeiler

Sehr gute Übung zur Klausurvorbereitung und zur
Überwindung der Mathe-Phobie

■ Lösungsidee 1: möglichst viel "erhalten"

– $ED(\text{"VERIEN"}, \text{"FERIEN"}) = 1$

Einfach, weil die Zeichenketten größtenteils gleich

– $ED(\text{"SEMESTERFERIEN"}, \text{"SEMESTERVERIEN"}) = 1$

Dito ... dann auch für längere Zeichenketten noch einfach

– $ED(\text{"MEXIKO"}, \text{"AMERIKA"}) = 3$

Auch hier gibt es noch relativ große Übereinstimmung

– $ED(\text{"AAEBEAABEAREEEAE"}, \text{"RBEAAEEBAAAEBBAE"}) = ?$

Spätestens hier wird es sehr schwierig mit dieser Idee

■ Lösungsidee 2: in zwei Hälften teilen

- In zwei gleich große Hälften teilen und die dann jeweils rekursiv lösen

$$ED(\text{GRAU}, \text{RAUM}) = 2$$

$$ED(\text{GR}, \text{RA}) = 2$$

$$ED(\text{AU}, \text{UM}) = 2$$

- **Keine gute Idee:** die ED zwischen den Hälften hat nicht viel zu tun mit der ED zwischen den ursprünglichen Zeichenketten

Formal: wenn $x = x_1x_2$ und $y = y_1y_2$, dann ist im Allgemeinen **nicht** $ED(x, y) = ED(x_1, y_1) + ED(x_2, y_2)$

■ Lösungsidee 3: alternative rekursive Formel

- Das Problem auf ein Problem "eins kleiner" zurückführen
- $ED(\text{"FERIEN"}, \text{"VERIEN"}) = ED(\text{"FERIE"}, \text{"VERIE"}) = 1$

Weil die Worte rechts mit dem selben Buchstaben aufhören

- $ED(\text{"SAUM"}, \text{"RAUS"}) = ED(\text{"SAU"}, \text{"RAU"}) + 1 = 2$

Weil eine optimale Folge ein replace am Ende macht

Das gilt aber nicht immer, wenn sich die letzten beiden Buchstaben unterscheiden, zum Beispiel:

$$2 \neq ED(\text{"RAUM"}, \text{"GRAU"}) \neq ED(\text{"RAU"}, \text{"GRA"}) + 1 = 3$$

- Mit einer etwas komplizierteren Formel kriegt man es aber hin, das sehen wir jetzt auf den nächsten Folien

Rekursive Formel 1/7

$INS(1,U)$ $INS(1,A)$ $INS(1,S)$
DOOF \rightarrow UDOOF \rightarrow AUDOOF \rightarrow SAUDOOF
nicht monoton

$INS(1,S)$ $INS(2,A)$ $INS(3,U)$
DOOF \rightarrow SDOOF \rightarrow SADOOF \rightarrow SAUDOOF
das ist monoton

UNIVERSITÄT FREIBURG

■ Monotonie

- Seien **x** und **y** unsere beiden Zeichenketten
- Seien $\sigma_1, \dots, \sigma_k$ eine Folge von $k = ED(x, y)$ Operationen, für $x \rightarrow y$, das heißt, um x in y zu überführen

Wir nehmen im Folgenden nicht an, dass wir die Folge schon kennen, sondern nur, dass es so eine gibt

- Eine Folge von Operationen heißt **monoton**, wenn die Position von σ_{i+1} ist \geq die Position von σ_i , wobei $=$ nur dann erlaubt ist, wenn beides "delete" Operationen sind

Eine Folge von delete Operationen mit **gleichen** Positionen braucht man zum Beispiel bei $ED(\text{"saudoo"}, \text{"doof"})$

SAUDOOF \rightarrow AUDOOF \rightarrow UDOOF \rightarrow DOOF
 $DELETE(1)$ $DELETE(1)$ $DELETE(1)$

■ Hilfssatz zur Monotonie

- **Lemma:** Für beliebige x und y mit $k = ED(x, y)$ gibt es eine monotone Folge von k Operationen für $x \rightarrow y$
- Der Beweis ist Aufgabe 1 vom ÜB11
- Beweisidee 1: für den Fall $k = 2$ (zwei Operationen), muss man sich im Prinzip nur alle neun Kombinationen der drei Arten von Operationen anschauen
- Beweisidee 2: eine allgemeine nicht-monotone Folge lässt sich durch "Nachbartranspositionen" immer in eine monotone Folge derselben Länge überführen

Nachbartransposition = zwei Operationen hintereinander in nicht-monotoner Reihenfolge werden "umgedreht"

Rekursive Formel 3/7

Beispiele für die Fälle

FALL 1A: $\overset{x}{\text{GRAU}} \xrightarrow[\sigma_1]{z} \overset{z}{\text{RAU}} \xrightarrow[\sigma_2]{y} \overset{y}{\text{RAUM}}$

FALL 1B: $\overset{x}{\text{BÄUME}} \xrightarrow[\sigma_1]{z} \overset{z}{\text{BAUME}} \xrightarrow[\sigma_2]{y} \overset{y}{\text{BAUM}}$

FALL 1C: $\overset{x}{\text{DOOF}} \xrightarrow[\sigma_1, \sigma_2, \sigma_3]{z} \overset{z}{\text{BLOEF}} \xrightarrow[\sigma_4]{y} \overset{y}{\text{BLOED}}$

■ Fallunterscheidung

- Wir betrachten die letzte Operation σ_k

$\sigma_1, \sigma_2, \sigma_3$ DOOF BLOEF σ_4 BLOEF BLOED
 $\sigma_1, \dots, \sigma_{k-1} : \overset{4}{x} \rightarrow \overset{5}{z}$ und $\sigma_k : \overset{5}{z} \rightarrow \overset{5}{y}$

Seien $n = \overset{4}{|x|}$ und $m = \overset{5}{|y|}$ und $m' = \overset{5}{|z|}$

Man beachte, dass $m' \in \{m - 1, m, m + 1\}$
 σ_2 : INSERT REPLACE DELETE

- **Fall 1:** σ_k macht etwas "ganz am Ende" von z :

Fall 1a: $\sigma_k = \text{insert}(m' + 1, y[m])$ [dann ist $m' = m - 1$]

Fall 1b: $\sigma_k = \text{delete}(m')$ [dann ist $m' = m + 1$]

Fall 1c: $\sigma_k = \text{replace}(m', y[m])$ [dann ist $\underset{|z|}{m'} = \underset{|y|}{m}$]

Wenn keines von den dreien der Fall ist, dann sind die letzten Zeichen von x und y (und z) gleich ... siehe nächste Folie

■ Fallunterscheidung

- Wir betrachten die letzte Operation σ_k

$$\sigma_1, \dots, \sigma_{k-1} : x \rightarrow z \quad \text{und} \quad \sigma_k : z \rightarrow y$$

$$\text{Seien } n = |x| \text{ und } m = |y| \text{ und } m' = |z|$$

$$\text{Man beachte, dass } m' \in \{m - 1, m, m + 1\}$$

- **Fall 2:** σ_k macht nichts "ganz am Ende" von z

$$\text{Dann } z[m'] = y[m] \text{ und } x[n] = z[m']$$

$$\text{Damit } \sigma_1, \dots, \sigma_k : x[1..n-1] \rightarrow y[1..m-1] \text{ und } x[n] = y[m]$$

$$\underline{\text{DOOFI}} \longrightarrow \text{BLOED}\underline{\text{I}}$$

$\sigma_1, \sigma_2, \sigma_3, \sigma_4$

■ Wir haben also einen dieser vier Fälle

- Fall 1a (**insert** am Ende): $\sigma_1, \dots, \sigma_{k-1} : x[1..n] \rightarrow y[1..m-1]$
- Fall 1b (**delete** am Ende): $\sigma_1, \dots, \sigma_{k-1} : x[1..n-1] \rightarrow y[1..m]$
- Fall 1c (**replace** am Ende): $\sigma_1, \dots, \sigma_{k-1} : x[1..n-1] \rightarrow y[1..m-1]$
- Fall 2 (**nichts** am Ende): $\sigma_1, \dots, \sigma_k : x[1..n-1] \rightarrow y[1..m-1]$

Wichtig für die Formel auf der nächsten Seite: diese vier Fälle decken **alle** Möglichkeiten ab, andere gibt es nicht

■ Daraus folgt die folgende rekursive Formel

- Für $|x| > 0$ und $|y| > 0$ ist $ED(x, y)$ das **Minimum** von
 - $ED(x[1..n], y[1..m-1]) + 1$ ^{INS} *das +1 steht für die jeweils letzte Operation*
 - $ED(x[1..n-1], y[1..m]) + 1$ ^{DEL}
 - $ED(x[1..n-1], y[1..m-1]) + 1$ ^{REP} ... falls $x[n] \neq y[m]$
 - $ED(x[1..n-1], y[1..m-1])$... falls $x[n] = y[m]$

Jeder der vier führt zu einer möglichen Folge, und wir wissen, dass die minimale Folge dabei ist, deswegen das **Minimum**

- Für $|x| = 0$ ist $ED(x, y) = |y|$
- Für $|y| = 0$ ist $ED(x, y) = |x|$

■ Alternative Sichtweise

- Visualisieren einer Folge von Operationen, indem man **x** und **y** mit geeigneten "Lücken" untereinander schreibt

x ^{REP REP} **D O O** ^{INS REP REP INS} **V M** ^{DEL REP} **A N N**
y **B L O E D F R A** **U**

8 OPERATIONEN

insert = oben leer, darunter ein Buchstabe

delete = unten leer, darüber ein Buchstabe

replace = zwei ungleiche Buchstaben übereinander

- Wenn man da jetzt von links nach rechts durchgeht, hat man wieder genau eine monotone Folge
- Die rekursive Formel unterscheidet die vier Möglichkeiten in der letzten Spalte (insert, delete, replace, nix)

■ Code

- Mit der Formel von der Folie vorher können wir jetzt sehr leicht ein rekursives Programm schreiben
- Es funktioniert auch! (immerhin)

Aber es dauert unverhältnismäßig lange, selbst schon für relative kurze Zeichenketten

■ Laufzeit

- Für die Laufzeit gilt folgende rekursive Formel

$$T(n, m) = T(n-1, m) + T(n, m-1) + T(n-1, m-1) + \Theta(1)$$

$\geq T(n-2, m-1) \geq T(n-1, m-1)$

- Insbesondere:

$$T(n, n) \geq 3 \cdot T(n-1, n-1) \geq 3 \cdot 3 \cdot T(n-2, n-2) \geq \dots$$

- Also:

$$T(n, n) \geq 3^{n-1} \cdot T(1, 1) \geq 3^{n-1}$$

Also **exponentielle** Laufzeit, wie auch schon bei der rekursiven Fibonacci-Berechnung

*Insbesondere: Zeichenketten um 1 länger
→ drei mal so lange*

Rekursive Implementierung 4/4

■ Problem

- Das rekursive Programm berechnet die gleichen ED Werte **immer und immer wieder**

Das hatten wir auch schon bei der Berechnung der Fibonacci Zahlen gesehen (in Vorlesung 1b)

z.B. $ED(ab, cd)$

1 = ein rekursiver Aufruf

19 AUFRUFE

Basisfall

	ϵ	c	d
ϵ			
a			
b			

diese Zelle entspricht $ED(\epsilon, cd)$

← Basisfall

die drei $ED(ab, c)$

■ Editierdistanz

- In Wikipedia (Definition + Algorithmen)

http://en.wikipedia.org/wiki/Levenshtein_distance

<http://de.wikipedia.org/wiki/Levenshtein-Distanz>